

Prise en compte du bruit dans la segmentation floue d'image en couleur: état de l'art

Hichem Boussaid, Aissatou Signate

December 20, 2022

1 Introduction

La segmentation d'images est une technique très utile dans beaucoup de domaines de la vision par ordinateur, tels que le traitement d'images médicales, l'analyse d'images pour la détection et la reconnaissance de visages, dans le domaine des images satellitaires, ou encore des voitures autonomes. Son but est de diviser une image en régions qui se ressemblent, qui ne se chevauchent pas et qui restent cohérentes selon les exigences de l'application. Ce regroupement de pixels se fait grâce à des critères spatiaux ou d'intensité.

La segmentation d'images reste une tâche compliquée dans le domaine de la vision par ordinateur et la compréhension d'images, car le type ou le niveau de segmentation dépend d'une application à une autre, et le résultat dépend énormément de la variété et la complexité des images. C'est pour cela que jusqu'à aujourd'hui, la littérature n'arrive toujours pas à avoir un système qui soit efficace et robuste pour un grand nombre d'images. Dans le but d'améliorer les résultats de la segmentation, plusieurs techniques ont été proposées dans la littérature telles que: Détection de Contours [1], *Clustering* [2], [3], *Region Growing* [4], *Watershed Transform* [5], modèle de Contours Actifs [6], Les champs aléatoires de Markov [7], Réseaux de neurones [8], etc.

Le *Clustering*, dont le but est d'assigner des composantes qui se ressemblent à un même groupe, est une des méthodes les plus utilisées lorsqu'il s'agit de segmentation d'images parce qu'elle se veut très rapide et efficace. Cependant les techniques classiques de *clustering* (communément appelées *Hard Clustering*) ne laissent pas place à l'ambiguïté, c'est à dire que les points de données n'appartiennent qu'à un seul groupe uniquement, alors qu'en réalité ils peuvent appartenir à plus, et c'est pour palier à ce problème que la théorie des ensembles flous ou encore *Fuzzy Sets* a été proposé par Zadeh [9]. L'avantage principal de cette méthode est qu'elle permet une appartenance graduelle d'une donnée à plusieurs groupes (ou *clusters*), les degrés appartenant à $[0,1]$ (C'est à dire qu'un point pourrait appartenir à 60% au *Cluster 1* et à 40% au *Cluster 2* par exemple), et parmi les méthodes de *Clustering* Flou les plus utilisés dans la segmentation d'images nous retrouvons le *Fuzzy C-Means* (FCM) proposé par Bezdek et al. [10], et qui donne d'excellents résultats lorsque l'image est simple et non bruitée, mais reste très sensible aux bruits.

Le but de notre état de l'art s'intéresse justement à l'effet du bruit sur la segmentation d'images couleurs avec le *Clustering* Flou. D'abord dans la section 2. expliquer en détails l'algorithme FCM, puis dans la section 3. passer en revue les principales méthodes utilisées pour pallier ce problème, la section 4. servira de discussion sur ces méthodes, et enfin la conclusion dans la section 5.

2 Qu'est-ce que le clustering flou ?

De nombreuses méthodes ont été utilisées dans la littérature pour extraire les informations nécessaires d'une image afin de la partitionner en différentes régions. Cependant, la majorité de ces méthodes n'arrivent pas à trouver un bon compromis entre le temps de calcul et la précision. Cela est principalement dû à l'ambiguïté que l'on peut trouver sur les images réelles, causée par les contours d'objets qui ne sont pas très bien définis. Avec des images réelles nous pouvons très souvent tomber dans des cas avec des régions ambiguës. Les méthodes classiques qui utilisent que l'intensité des pixels pour discriminer les régions peinent à avoir de bons résultats avec les pixels de intensités similaires. En prenant en compte la grande corrélation des pixels adjacents, nous pouvons avoir une bien meilleure précision sur ces régions.

Ainsi en s'intéressant à la segmentation d'images avec le clustering flou, la littérature a pu proposer beaucoup d'algorithmes, mais celui qui est le plus accepté et utilisé jusqu'à ce jour est l'algorithme Fuzzy C-Means (FCM). Cet algorithme se base sur une minimisation itérative de la fonction objective, et sur une norme euclidienne pour calculer la distance entre un pixel et le centre d'un cluster. Les centres de clusters s'adaptent après chaque itération après avoir été initialisés aléatoirement ou avec une méthode d'approximation.

De manière formelle, l'algorithme FCM, essaie de partitionner les niveaux de gris x_i des pixels i (avec $i = 1, 2, \dots, N$) d'une image I dans une collection de C classes avec $C \geq 2$ en assignant une valeur d'appartenance pour chaque pixel i à un cluster c_j (avec $j = 1, 2, \dots, C$).

La fonction objective est :

$$J_{fcm} = \sum_{i=1}^N \sum_{j=1}^C w_{ij} \|x_i - c_j\|^2 \quad (1)$$

avec la fonction d'appartenance:

$$w_{ij} = \frac{1}{\sum_{k=1}^C \left(\frac{\|x_i - c_j\|^2}{\|x_i - c_k\|^2} \right)^{\frac{1}{(m)-1}}} \quad (2)$$

et le centroids sont:

$$C_j = \frac{\sum_{i=1}^N w_{ij}^m x_i}{\sum_{i=1}^N w_{ij}^m} \quad (3)$$

Au final ce *Clustering Flou* (ou *Fuzzy Clustering*) donne de bien meilleurs résultats en segmentation d'images que le clustering classique surtout pour les images avec des textures simples. Ces méthodes tendent à devenir moins bonnes dès qu'on commence à travailler sur des images complexes, ou des images réelles. L'un des principaux problèmes de ces images est la présence du bruit, qui peut être simple tels que les bruits Gaussiens, Poissons ou Impulsionnel, mais sur des images réelles c'est très rare, nous retrouvons plutôt un mélange de plusieurs types de bruits ou du bruit inconnu, ce qui rend la segmentation très difficile et fait chuter les résultats de beaucoup de méthodes qui utilisent FCM.

Dans le but d'améliorer la robustesse face au bruit beaucoup de méthodes ont été proposées, et nous avons décidé d'utiliser la classification suivante:

- Méthodes utilisant l'information spatiale
- Méthodes basées sur la fonction *Kernel*
- Méthodes basées sur les techniques mathématiques.

Cette classification a été choisie car elle se dégage naturellement dans la littérature. Nous pouvons trouver d'abord l'utilisation de l'information spatiale pour améliorer la robustesse au bruit de la segmentation. Pour résoudre le problème de linéarité, les approches basées sur la fonction *Kernel* sont devenues très en vogue. Enfin, ne trouvant toujours pas de bon compromis entre la robustesse et le temps de calcul, différentes techniques mathématiques ont été utilisées. La figure 1. est un diagramme résumant cette classification, avec les méthodes les plus importantes à chaque catégorie.

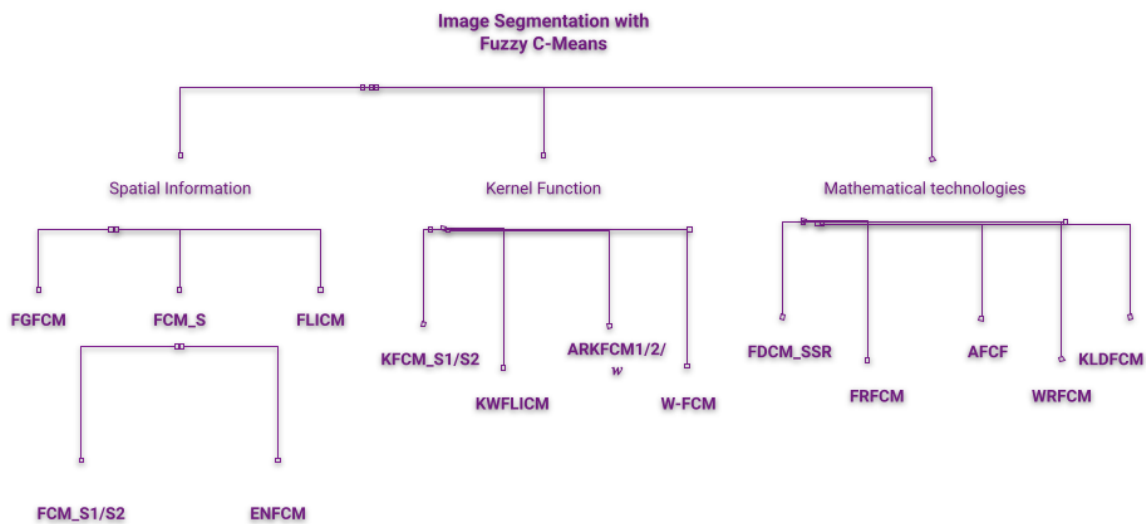


Figure 1: Synthèse de classification des approches, avec les algorithmes les plus importants pour chaque catégorie.

2.1 Méthodes utilisant l'information spatiale

L'utilisation de l'information spatiale a été l'une des premières méthodes qui améliora la robustesse du FCM au bruit. Avec Ahmed et al.[11] en 2002, qui ont proposé un algorithme pour la segmentation adaptative et la correction d'intensité des images IRM. Cet algorithme est appelé dans la littérature FCM_S. Il a pour but d'étiqueter un pixel en compensant l'hétérogénéité d'intensité dans les images par l'influence du voisinage direct de ce pixel. En effet, cet algorithme utilise le voisinage comme un régulateur qui oriente la solution vers un étiquetage homogène par morceaux. FCM_S a été appliqué sur des images d'IRM simulée, et

des images réelles revues par les experts et a été comparé aux résultats d'un FCM standard, et sur les deux jeux de données la méthode d'Ahmed et al. a donné de bien meilleurs résultats. Ajouté à cela l'un des plus grands avantages de cette méthode en ce temps-là, a été le fait que les variations d'intensité entre les patients, les scans et les changements d'équipement ont été pris en compte dans le champ de biais estimé sans nécessiter d'intervention manuelle. Cependant, les résultats présentés dans cet article étaient préliminaires et l'une des plus grandes limitations de cette méthode est le temps de calcul, qui est très grand à cause du terme de voisinage spatial qui est calculé à chaque itération, et cet article a ouvert la porte à de nouvelles recherches.

Szilagyi et al. [12] ont proposé un algorithme dont le but était d'améliorer la vitesse de FCM_S, qu'ils ont nommé ENFCM pour *Enhanced FCM*, en effectuant un clustering basé sur les histogrammes de niveaux de gris au lieu des pixels d'une image. Ainsi, en prenant en compte l'idée que le nombre de niveaux de gris dans une image est généralement beaucoup plus petit que le nombre de ses pixels. Cet algorithme a été appliqué sur des images IRM et la segmentation a été comparée à la vérité terrain. Le temps de calcul a nettement baissé tout en ayant une segmentation similaire à FCM_S.

Ensuite Chen et Zhang [13], ont eux aussi voulu améliorer la vitesse du FCM_S, en proposant deux approches qui ont été nommées FCM_S1 et FCM_S2, qui remplacent le terme de voisinage utilisé dans FCM_S par la moyenne et la médiane. Comme ces valeurs peuvent être calculées en avance, le temps de calculs de ces nouvelles méthodes a considérablement chuté comparé à l'algorithme d'Ahmed et al. Comparé à la méthode de Szilagyi et al. [2] le temps de calcul de FCM_S1 et FCM_S2 reste plus élevé, mais la segmentation est plus robuste contre le bruit sel & poivre.

Après ça, Cai et al. [14] ont dénoté 3 problèmes aux méthodes que nous venons de voir:

- Le paramètre α , qui est très important dans la fonction objective dont le but est de trouver une balance entre la robustesse face au bruit et les détails de l'image à segmenter, et dont la définition se fait de manière empirique.
- La relation spatiale utilisée bien qu'elle améliore la robustesse par rapport au FCM standard reste très limitée surtout si nous n'avons pas de connaissance a priori sur le bruit présent dans l'image.
- Le temps de calcul de ces méthodes est dépendant de la taille de l'image à segmenter et donc plus l'image est grande plus le temps de calcul l'est aussi.

Pour résoudre des problèmes, Cai et al. ont introduit une nouvelle mesure de similarité locale S_{ij} , dont les principaux avantages sont le fait qu'elle rend l'algorithme moins dépendant des connaissances a priori sur le bruit, elle utilise la relation spatiale et la relation d'intensité locale entre les pixels, et enfin S_{ij} peut être automatiquement calculé par ces relations. Ensuite pour améliorer le temps de calcul de leur algorithme ils utilisent la méthode [12] ce qui rend le temps de calcul indépendant de la taille de l'image. Enfin, en introduisant la moyenne et la médiane pour avoir FGFCM_S1 et FGFCM_S2 respectivement ils ont pu faire chuter grandement le temps de calcul de leur algorithmes. Au final, avec cet algorithme Cai et al. [14] ont pu obtenir de très bons résultats avec une segmentation très

robuste, et en préservant la qualité de l'image, mais leur algorithme avait au final encore plus de paramètres à sélectionner.

En voulant trouver une méthode qui puisse être robuste aux bruits, qui préserve la qualité de l'image, et sans paramètres à sélectionner Krinidis et al. [15] ont proposé un nouvel algorithme qu'ils ont nommé *Fuzzy Local Information C-Means* (FLICM), qui introduit dans la fonction objective un nouveau facteur G_{ki} , qui aura pour caractéristiques:

- Préserver la robustesse au bruit grâce à l'utilisation de la localité spatiale et d'intensité
- Contrôler l'influence du voisinage de chaque pixel par rapport à leur distance du centre,
- Utiliser l'image originale au lieu d'appliquer un prétraitement,
- Être dispensé de toute sélection de paramètres.

Cependant, cette méthode bien qu'elle ait résolu le problème des paramètres, sa distance spatiale fixée rend l'algorithme non applicable à des informations spatiales arbitraires.

Un tableau récapitulatif des méthodes utilisant l'information spatiale avec FCM est donné. Tab 1.

Approche	Amélioration	Méthode
FCM_S	Robustesse au bruit	Introduction information spatiale.
ENFCM	Temps de calcul	Histogramme des niveaux de gris
FCM_S1/S2	Temps de calcul	Filtrage moyen et médian
FGFCM_S1/S2	Robustesse au bruit	Mesure de similarité locale S_{ij}
FLICM	Robustesse au bruit	Nouveau facteur G_{ki}

Tab 1. Récapitulatif des algorithmes présentés, avec leur but et la méthode utilisée.

2.2 Méthodes utilisant distance *Kernel*

La méthode de la fonction *kernel* consiste à transformer les informations en entrée d'un espace de basse dimensions en un autre espace de plus grande dimensions où les données pourront être bien mieux séparées.

Dans [13], Chen et Zhang décrivent deux manières d'utiliser cette méthode avec FCM et FCM_S. La première consiste à considérer chaque centroïde comme un point cartographié dans l'espace des caractéristiques et à utiliser leurs formes duales. C'est-à-dire une combinaison linéaire de tous les échantillons de données, pour remplacer les centroïdes originaux. Tout cela, dans le but d'obtenir des résultats de clustering dans l'espace des caractéristiques au lieu l'espace original, sauf que cette méthode est jugée difficilement interprétable dans l'espace original. La deuxième méthode quant à elle, consiste à considérer

chaque centroïde comme un point de données dans l'espace d'origine. À les transformer directement avec les échantillons de données dans les espaces de caractéristiques, puis à effectuer le clustering. De cette manière le résultat du clustering est facilement interprétable.

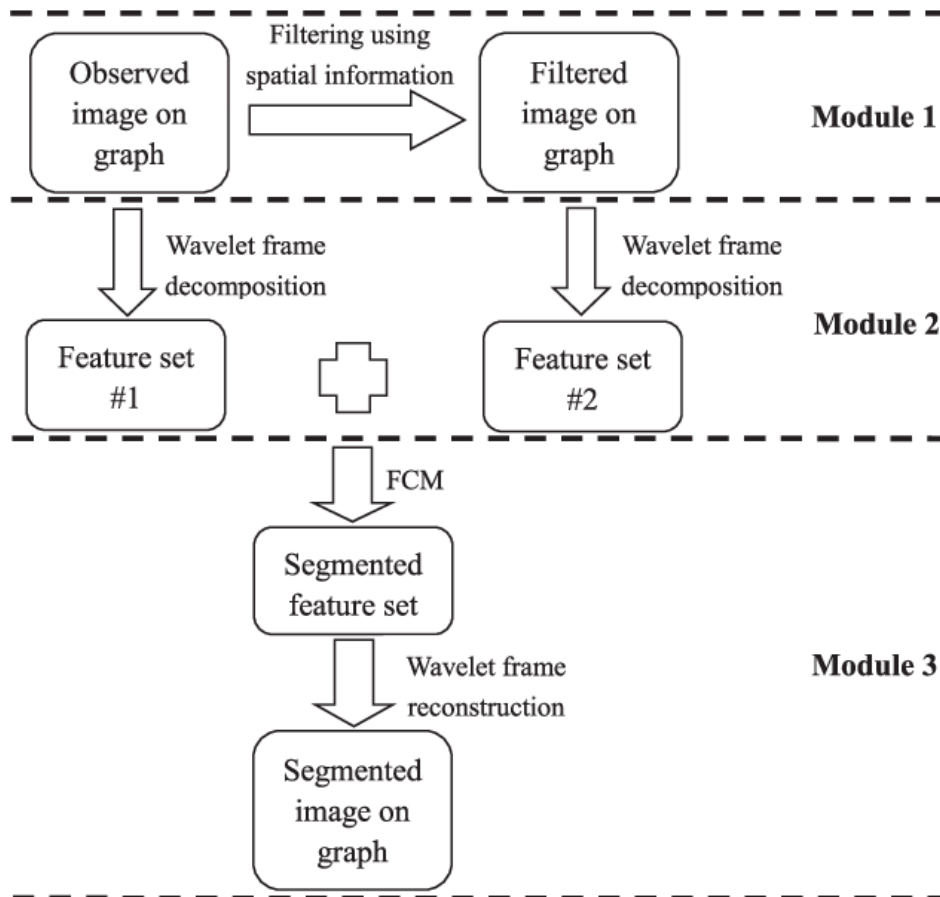
Ainsi, dans la deuxième partie de [13], ils ont utilisé la deuxième méthode en appliquant aussi les contraintes spatiales de FCM_S1 et FCM_S2, pour donner deux nouveaux algorithmes qu'ils ont nommés KFCM_S1, et KFCM_S2. Le noyau utilisé pour ces méthodes était un Noyau RBF Gaussien (GRBF), et au final ces deux méthodes, donnaient de meilleurs résultats et étaient plus robustes aux bruits que FCM_S1 et FCM_S2, cependant leurs algorithmes ont une grande limite qui est le choix du paramètre σ pour le GRBF, qui a une grande influence sur les performances des algorithmes, et qui a été choisi empiriquement.

Ensuite, Gong et al. [16], ont présenté une nouvelle approche pour surmonter les limites de FLICM et en même temps introduire une nouvelle règle de sélection rapide pour déterminer le paramètre σ du GRBF. En effet, même si le facteur G_{ki} rendait l'algorithme bien plus robuste aux bruits, ils ont dénoté que lorsque le pixel au centre de la fenêtre est bruité l'algorithme avait du mal à analyser l'impacte de chaque pixel du voisinage, c'est pour cela que Gong et al. [17] avaient proposé une variante du facteur G_{ki} , qui utilise les coefficients de variations locale plutôt qu'une distance spatiale pour rendre la relation entre le pixel central et son voisinage relativement conforme aux niveaux de gris. Sauf que dans [6] ils ont jugé que c'était déraisonnable d'ignorer la relation spatiale dans un voisinage, surtout que ce nouveau calcul ne pouvait pas être aussi exact que l'utilisation des niveaux de gris et la relation spatiale en même temps. Avec tout cela, ils ont proposé un nouvel algorithme nommé KWFLICM, qui utilise un nouveau facteur flou pondéré G_{ki}' qui utilise en même temps les contraintes de relation spatiale et de niveau de gris, avec une fonction objective qui utilise une distance non-euclidienne basée sur GRBF, avec le paramètre σ déterminé grâce à la variance de la distance de tous les points par rapport au centre des données du voisinage. Les expérimentations ont été menées sur des images synthétiques, médicales et naturelles, avec des bruits gaussiens, sel et poivre et riciens, et les résultats montre que KWFLICM est très robuste à ce type de bruits, et donne ses performances sont bien meilleurs, mais son temps de calcul est très élevé car le facteur G_{ki}' doit être calculé à chaque itération.

Après cela, Szilágyi[18] a fait une analyse sur FLICM (et par héritage KWFLICM) et a prouvé des erreurs théoriques conséquentes de cette approche, en mentionnant que l'optimisation itérative ne minimisent pas la fonction objective, et que cette dernière n'inclut l'information contextuelle locale sur aucun pixel. Alors, dans le but de surmonter les problèmes de la segmentation d'images IRM, Elazab et al. [19] ont proposé un nouveau variant de FCM basé sur un noyau régularisé de manière adaptative, qui peut être vu sous la forme de trois algorithmes. En effet, l'apport principal de cette méthode a été le paramètre adaptatif φ_i qui est estimé grâce aux coefficients des variations locales. Ce paramètre se base sur l'hétérogénéité de la distribution des niveaux de gris dans le voisinage local, alors que les anciennes méthodes se basent sur les différences de niveaux de gris entre les pixels et les centres de *clusters*. Ce paramètre peut être calculé à l'avance et ce qui diminue le temps de calcul de l'approche. Cette approche a été divisé en trois algorithmes ARKFCM1, ARKFCM2 et ARKFCM_w, qui utilisent respectivement la médiane, la moyenne et l'image pondérée créée en utilisant le paramètre φ_i , pour ce qui est de la distance ils utilisent GRBF et

calculent le paramètre σ de la même manière que [16]. Au final, la méthode ARKFCM a été testé sur des images IRM synthétiques et réelles avec différent types de bruits et non-uniformité des niveaux de gris incorporés, et les résultats montre un excellent compromis entre robustesse contre le bruit et temps de calcul, cependant une des limitations de cette algorithme est la sensibilité au bruit importante dans de petites zones entre des bords.

Enfin, Wang et al. [20] jugent que l'inconvénient des méthodes utilisées jusqu'à présent est qu'ils ne prennent pas en compte la distribution de l'espace des caractéristiques des données d'image lors de la formulation des clusters et proposent une nouvelle approche FCM basée sur les ondelettes pour la segmentation d'images sur les graphes. En effet, leur méthode utilise des images observés sur des graphes pour d'abord les filtrer grâce à l'information spatiale disponible, en suite un système d'ondelettes (*tight wavelet frames*) est utilisé pour obtenir les hautes et les basses fréquences à partir de l'image originale et de l'image filtré observés pour utiliser FCM pour la segmentation de ce nouvel espace et enfin pouvoir reconstruire l'image segmentée grâce à la transformation d'ondelettes sur les graphes (voir figure 2.). Cet algorithme nommé W-FCM a été appliqué sur des images synthétiques et *Global Earth observation data* qui sont des images sur graphes, en ajoutant différents type de bruits: Gaussien, Sel et Poivre, Poisson, Impulsionnel, ainsi qu'un mélange Poisson-Gaussien et Impulse-Gaussien. Au final, W-FCM donne de meilleurs résultats de segmentation et est robuste à ce type de bruit tout en conservant les détails des images sur les graphes, même si son temps de calcul est plus élevé que les autres variants de FCM.



La figure 2, est le schéma de l'algorithme W-FCM proposé dans [10]

Un tableau récapitulatif des méthodes utilisant la fonction *Kernel* et leurs caractéristiques est présenté. Tab 2.

Approche	Amélioration	Méthode
KFCM_S1/S2	Robustesse au bruit	Introduction Noyau RBF Gaussien (GRBF)
KWFLICM	Robustesse au bruit	Utilisation GRBF et introduction du facteur G_{ki}'
ARKFCM1/2/ w	Robustesse au bruit/ Temps de calcul	Image pondérée et noyau GRBF
W-FCM	Robustesse au bruit	<i>Tight wavelet frames</i>

Tab 2. Récapitulatif des méthodes *Kernel* avec les améliorations qu'elle apporte, et la méthode utilisée.

2.3 Méthodes avec approche mathématiques

Voulant toujours améliorer la qualité de la segmentation avec un temps de calcul moindre, en plus des approches que nous avons citées dans la section précédentes, beaucoup d'approches basées sur les mathématiques ont été proposées.

Tout d'abord avec Gu et al. [21] proposent un algorithme de FCM double basé sur l'auto-représentation éparses qu'ils ont nommé *Fuzzy Double C-Means Clustering Based on Sparse Self-Representation* (FDCM_SSR). Les auteurs ont dénoté que les variants de FCM n'utilisent pas l'information globale des données, c'est pour cela qu'ils ont décidé d'introduire l'auto-représentation éparses qui contient l'information globale dans l'algorithme classique FCM. En effet, grâce à cette auto-représentation nous obtenons deux ensembles de caractéristiques qui peuvent avoir des dimensions et des mesures de distances différentes qui sont utilisés pour le *clustering*, le premier étant considéré comme un ensemble basique contenant l'information physique des données et le deuxième comme un ensemble discriminant obtenu grâce à l'application de l'auto-représentation sur le premier ensemble (voir figure 3.). FDCM_SSR a été appliqué sur des images synthétiques, naturelles, des images SAR, et des bases de données UCI (*Qualitative Bankruptcy*, *Auto MPG*, *Balance Scale*, *Contraceptive Method Choice*), et comparé à d'autres variants FCM et l'algorithme K-Means. Au final cette méthode est beaucoup plus robuste aux bruits et s'adapte aux données, mais les limitations de cette approche sont la sélection des paramètres d'ajustement λ et α , qui sont très importants pour la précision de la segmentation, ainsi que le temps de calcul qui reste plus élevé que les autres approches.




Figure 3. représente une matrice de coefficients éparses, obtenu en utilisant l'auto-représentation sur une image composée de quatre classes

Lei et al. [22] proposent une approche rapide et robuste de FCM en introduisant la reconstruction morphologique et filtrage d'appartenance: *Fast and Robust Fuzzy C-Means* (FRFCM). En effet, ils introduisent une reconstruction morphologique (MR) sur les niveaux de gris pour obtenir une image de meilleure qualité et qui rend l'approche bien plus robuste aux différents types de bruits (voir figure 4.), sans pour autant augmenter le temps de calcul car cette opération se fait à l'avance. Un *clustering* est appliqué sur l'histogramme des niveaux de gris de cette nouvelle image pour obtenir la matrice d'appartenance floue qui sera modifiée en utilisant le filtrage d'appartenance qui utilise un filtre médian. Cette méthode a été appliquée sur des images synthétiques (avec différents niveaux gaussien, sel et poivre, et uniforme), sur des images médicales réelles, des images d'aurores, et des images couleurs (en faisant le clustering sur les pixels au lieu de l'histogramme et en utilisant reconstruction morphologique multivariée). FRFCM est comparé à neuf autres variants de FCM et les expérimentations démontrent une meilleure robustesses aux différents types de bruits avec un temps de calcul plus faible que les autres méthodes, mais la limitation de cette méthode est qu'on ne peut pas utiliser l'histogramme des niveaux de gris sur les images couleurs et est décrite comme ayant des résultats instables par [24] à cause de la reconstruction morphologique qui peut perdre certaines informations.

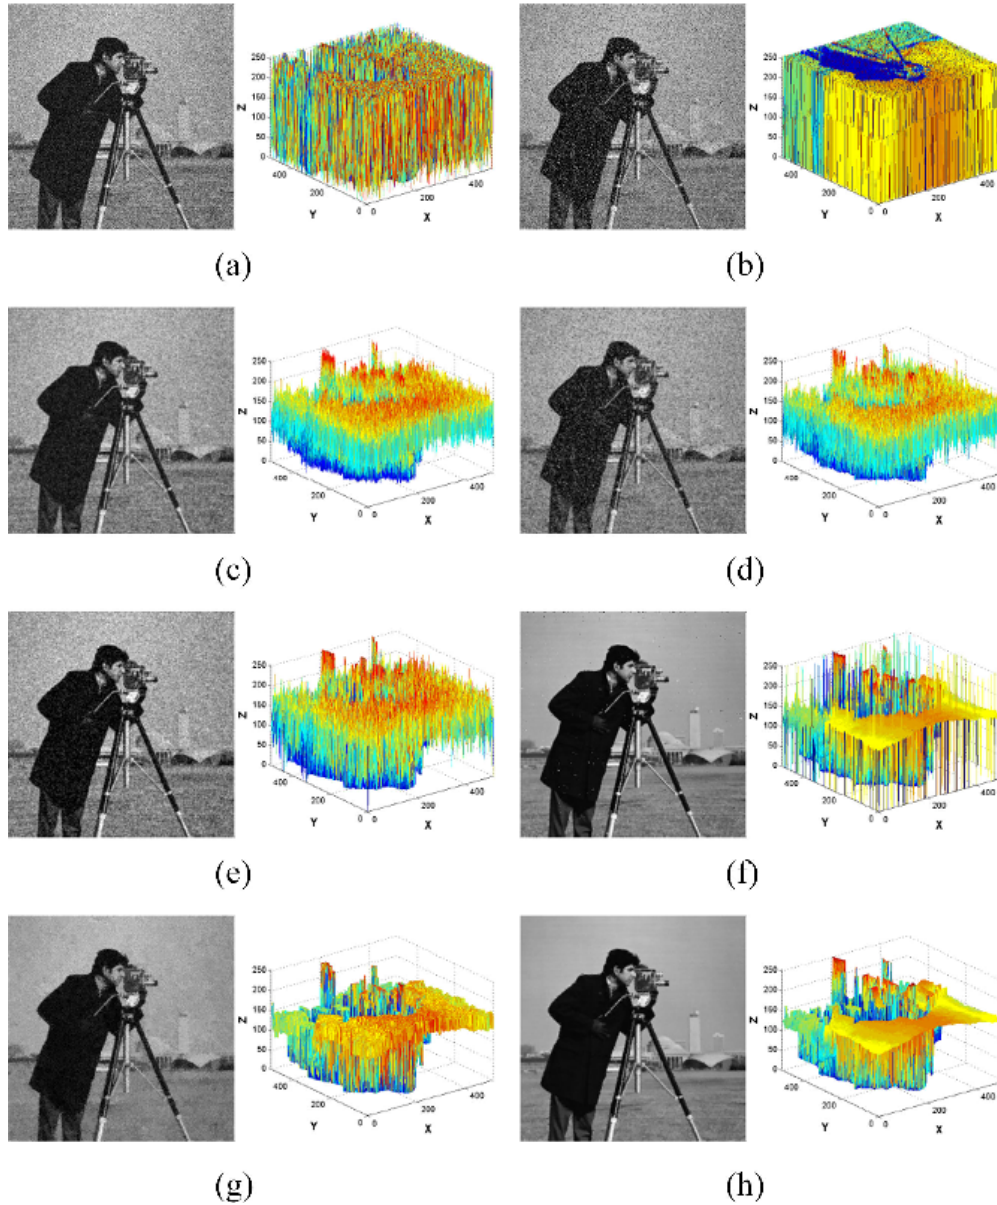


Figure 4. Comparaison du débruitage utilisant différentes méthodes. (a) Bruit gaussien (avec variance 5% et la valeur moyenne 0). (b) Image avec bruit sel et poivre (densité à 20%). (c) Résultat d'un filtre moyen sur (a). (d) Résultat d'un filtre moyen sur (b). (e) Résultat d'un filtre médian sur (a). (f) Résultat d'un filtre médian sur (b). (g) Résultat d'un filtrage MR sur (a). (h) Résultat d'un filtrage MR sur (b).

re

Lei et al. [23] ont proposé une nouvelle approche pour répondre aux problématiques que l'on a vu précédemment, mais surtout pour trouver automatiquement le nombre de *clusters* pour la segmentation d'images : *Automatic Fuzzy Clustering Framework* (AFCF). Cette méthode utilise d'abord un algorithme de Super Résolution (SR) pour faire une pré-segmentation de l'image, sur laquelle sera appliqué un algorithme de *Density Peak* (voir figure 5.), et en appliquant un algorithme d'équilibre de la densité, l'algorithme permet d'avoir un graphe de décision qui donne le nombre de *cluster*. Pour améliorer le résultat de la

segmentation, l'analyse de covariance et *Markov random field* sont intégrées à la fonction objective du FCM. Ensuite, trois algorithmes de SR ont été utilisés et même si le nombre des clusters était le même, MMGR-WT a donné une meilleure segmentation. Finalement, AFCF a été appliqué sur des images synthétiques couleurs avec du bruit gaussien et sel et poivre, et sur des images réelles du dataset Berkeley segmentation (BSDS500), et a été comparé avec 10 variants de FCM de l'état de l'art, cependant cette méthode a un temps de calcul qui est plus élevé que les autres variants FCM.




Figure 5. Résumé des différentes étapes de segmentations pour AFCF

Cong et al. [24] propose une nouvelle approche se basant sur les résidus entre une image idéale (sans bruits) et l'image réelle (bruitée), en proposant d'abord un *framework* nommé RFCM (voir figure 6.) qui se base sur la distribution des différents bruits, par exemple: un terme de fidélité 2-norm correspond à bruit gaussien et le bruit impulsif correspond un terme de fidélité 1-norm. Cependant comme dans les images réelles en général le bruit est inconnu ou un mélange de plusieurs bruits, ils décident d'introduire un terme de fidélité pondérée 2-norm avec un poids calculé automatiquement qui est assigné à chaque résidu. En ajoutant l'information spatiale entre chaque pixel et son voisinage, ils améliorent le résultat de la segmentation. Cette méthode a été nommée *Residual-driven FCM with Weighted* (WRFCM). Cette approche a été ensuite testée sur des images synthétiques en ajoutant du bruit gaussien, de poisson et impulsif, sur des images médicales de *BrianWeb*, et sur des images réelles des bases de données *Berkeley Segmentation DataSet*, *Microsoft Research Cambridge Object Recognition Image Database* (MSRC), et *NASA Earth Observation Database* (NEO), et a été comparé à sept variant de FCM de l'état de l'art. Finalement, WRFCM est plus robuste aux bruits inconnus et mélangés, tout en gardant les détails de l'image, cependant son temps de calcul reste plus élevé que d'autres variants, surtout comparé à FRFCM qui a des résultats légèrement moins bons avec un temps de calcul plus faible.

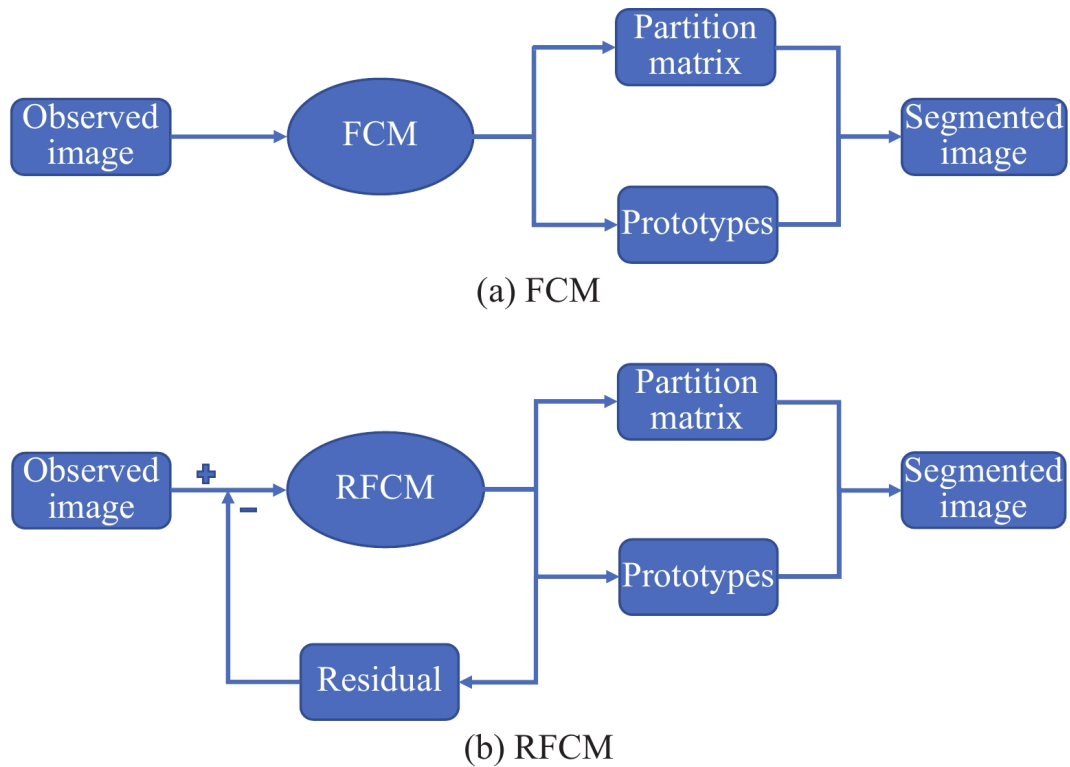


Figure 6. Schéma qui résume l'algorithme RFCM en le comparant à FCM

Enfin, Wang et al. [25] proposent une approche combinant plusieurs techniques pour essayer de répondre aux problèmes de robustesse aux bruits et le temps de calcul. Cette méthode nommée *Kullback-Leibler Divergence-Based Fuzzy C-Means* (KLDFCM) utilise un FCM basé sur la divergence Kullback-Leibler (KL), tout en introduisant la reconstruction morphologique et la transformation *tight wavelet frames*. En effet, KLDFCM utilise la distance de divergence KL, et pour diminuer sa complexité et utiliser une distance *kernel* robuste, elle utilise d'abord la reconstruction morphologique pour filtrer l'image bruitée, pour après utiliser les ondelettes sur cette image filtrée et donner un ensemble de caractéristiques composé de neuf dimensions (une pour les basses fréquences et les autres pour les hautes fréquences). Ensuite, pour améliorer le résultat de la segmentation, un processus de reconstruction sur l'ensemble des caractéristiques segmentées est introduit, et une fois que l'ensemble des caractéristiques modifiées est obtenu une reconstruction de l'image segmentée est réalisée grâce aux ondelettes (voir figure 7.). Avant de tester la robustesse de KLDFCM, Wang et al. ont fait une étude sur l'utilité de chaque partie dans cet algorithme avec dix compositions différentes. Ils ont conclu que la divergence KL augmente le temps de calcul de l'algorithme, mais elle reste très importante pour la segmentation et malgré cela le temps de calcul reste très bas grâce aux ondelettes et au filtrage morphologique. Finalement, cette méthode a été comparé à sept autres de l'état de l'art, et a été appliqué sur des images synthétiques avec des bruits mixte (gaussien-impulsionnel, poisson-gaussien) et du bruit ricien, sur des images médicales de BrianWeb, et sur des images réelles des bases de données BSDS et NEO. KLDFCM donne de meilleurs résultats qualitatifs sur toutes les images testées, mais le temps de calcul reste plus élevé que certains variants de FCM, rajouter à cela l'algorithme KLDFCM a des paramètres qui sont choisis manuellement.

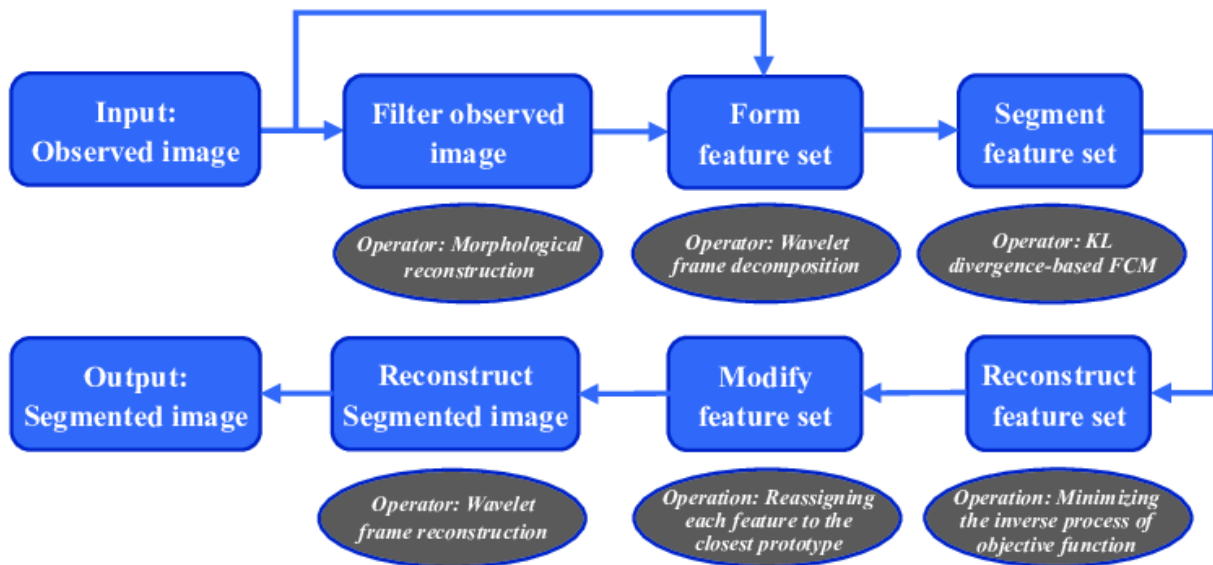


Figure 7. schéma simplifié de l'algorithme KLDFCM.

Approche	Amélioration	Méthode
FDCM_SSR	Robustesse au bruit	Auto-représentation épars
FRFCM	Robustesse au bruit/ Temps de calcul	Reconstruction morphologique
AFCF	Choix automatique du nombre de cluster	Super résolution et <i>Density Peak</i> .
WRFCM	Robustesse au bruit	Résidus de bruits, terme de fidélité 2-norm
KLDFCM	Robustesse au bruit	Divergence KL, reconstruction morphologiques, ondelettes

Tab 3. Récapitulatif des méthodes mathématiques, les améliorations apportées et la méthode utilisée.

3 Discussion

Dans la section 2 nous avons présenté les différentes catégories de segmentation d'images avec l'algorithme FCM, en décrivant les approches les plus importantes dans la littérature, et en présentant leurs avantages et limitations. Pour synthétiser toutes ces informations, cette partie servira de comparaison générale entre les trois catégories, mais avant cela, il faut définir les moyens de comparaison entre les différents algorithmes FCM.

Nous avons trois critères principaux pour mesurer l'efficacité d'une approche:

- Les résultats qualitatifs, où l'image segmentée est présentée pour visualiser la qualité de la segmentation et vérifier si des détails de l'image d'origine ont été perdus.

- La complexité algorithmique, dans cette catégorie les résultats présentés diffèrent d'un article à un autre, les mesures sont: l'ordre de grandeur de l'algorithme, les nombre d'itérations, et le temps d'exécution (en secondes).
- Les résultats quantitatifs, et pour mesurer ce critères les plus connus étant *Segmentation Accuracy* (SA) qui représente le nombre de pixels correctement classifié divisé par le nombre total de pixels. *Quantitative Index Score* (S) qui représente la mesure *Intersection Over Union* (IoU) entre les pixels classifiés et la vérité terrain. Mais aussi d'autres mesures telles que: [26], [27], [28], [29], [30], [31].

Cette multiplicité des mesures quantitatives et le choix des images lors des expériences rend la comparaison entre les différentes approches très difficile. C'est pour cela que dans les sous-sections qui suivent nous nous intéressons aux apports et aux limitations des différentes catégories pour définir le tableau 4., qui est un récapitulatif des variables à prendre en compte pour faire le choix d'un algorithme.

3.1 FCM avec information spatiale

L'ajout de l'information spatiale à l'algorithme *Fuzzy C-Means* est l'une des premières approches à être proposé pour améliorer la robustesse de ce dernier. En se référant au tableau 4., nous comprenons que ces méthodes restent sensibles aux bruits complexes et leur temps de calcul baisse drastiquement sur des images couleurs. C'est pour cela, que ces méthodes sont délaissées aujourd'hui, même si elles restent très rapides, et donnent de très bons résultats sur des images plus simples.

L'algorithme FSM_S a été le premier à introduire l'information spatiale, mais ce travail était préliminaire et laissait place à beaucoup d'améliorations. Chacune des méthodes qui a été proposé après ça à essayer de résoudre un ou plusieurs problèmes spécifiques de cet algorithme.

FCM_S1/S2, améliore la complexité de FCM_S, et sont plus robustes aux bruits gaussiens, mais sont plus sensibles au bruit sel et poivre. En réalité, la robustesse de cette méthode reste très limitée. Cependant, l'utilisation de la médiane et de la moyenne a laissé place à des améliorations qui sont bien meilleures.

ENFCM améliore encore plus la vitesse d'exécution, mais ne parvient pas à améliorer le niveau de segmentation comparé à FCM_S. Cette méthode n'est plus utilisée aujourd'hui, car d'autres algorithmes bien plus performants ont pu introduire l'histogramme des niveaux de gris pour améliorer leur temps de calculs.

FGFCM quant à lui améliore la robustesse face aux bruits sel et poivre et gaussiens, tout en améliorant la complexité de FCM_S, mais introduit d'autres paramètres à sélectionner. Cette méthode peut être très efficace, mais elle est dépendante au bruit, donc son utilisation est conseillée sur des images en niveaux de gris avec du bruit connu.

Enfin, FLICM améliore grandement la robustesse de la segmentation, tout ayant une sélection de paramètres automatiques. Cependant, cet algorithme perd en vitesse de calcul, et reste très sensible aux informations spatiales arbitraires à cause de sa distance euclidienne. Son utilisation est principalement conseillée sur des images avec des distributions linéaires,

car elle offre un très bon compromis entre le temps de calcul et la précision de la segmentation.

3.2 FCM avec *Kernel Function*

L'utilisation de l'information spatiale a pu améliorer la robustesse aux bruits, tout en gardant un temps d'exécution assez faible. Cependant, cette robustesse était toujours restreinte aux distributions linéaires à cause de la distance euclidienne utilisée. Pour résoudre ces problèmes, les solutions basées sur la fonction *Kernel* ont été introduites.

D'abord avec KFCM_S1/S2, en utilisant une distance GRBF et en considérant les centres des *clusters* comme des points de données de l'ensemble. Cette méthode a pu améliorer la robustesse de FCM_S1/S2, mais elle reste très dépendante du paramètre σ , et elle est considérée difficilement interprétable. C'est pour cela que cette méthode a été délaissée pendant plusieurs années.

L'algorithme KWFLICM en tant qu'amélioration à l'algorithme FLICM, en introduisant la distance GRBF, en faisant en sorte de choisir automatiquement le paramètre σ . Cette méthode se montre très robuste face à plusieurs types de bruits, cependant sa plus grande limitation reste son temps de calcul. KWFLICM donne de très bons résultats sur images en niveaux de gris avec du bruit inconnu et répandu.

ARKFCM utilise les informations contextuelles locales, l'hétérogénéité des niveaux de gris et une distance GRBF, cet algorithme offre un bon compromis entre la segmentation et le temps d'exécution. Cependant, ARKFCM et ses variants sont très sensibles aux bruits sur les bords. Cet algorithme peut être utilisé sur des images d'IRM réelles pour une segmentation robuste et rapide.

W-FCM est la méthode avec la segmentation la plus robuste parmi ces méthodes. En utilisant les ondelettes et les images sur les graphes. Cet algorithme se montre très robuste face à plusieurs types et niveaux de bruits, mais son temps de calcul est plus élevé. W-FCM reste malgré cela l'un des meilleurs algorithmes pour la segmentation d'images sur des graphes.

3.2 FCM basé sur les mathématiques

Les approches basées sur les technologies mathématiques sont nombreuses dans la littérature, le but étant d'améliorer la robustesse tout en gardant un bon compromis avec la vitesse d'exécution.

FDCM_SSR utilise l'information globale de l'image grâce à l'auto-représentation pour mieux différencier les différentes classes. Les limitations de cette méthode sont le temps d'exécution qui est plus élevé que pour les anciennes méthodes, et le choix des paramètres λ et α . FDCM_SSR offre une segmentation très robuste aux différents types et niveaux de bruits, mais l'image segmentée perd des détails de l'image originale. C'est pour cela que cet algorithme est à utiliser sur des images très complexes dans des applications où nous n'avons pas besoin des détails de l'image après segmentation.

FRFCM utilise la reconstruction morphologique et un filtrage d'appartenance. En réalité, cette méthode est considérée parmi les meilleures dans la littérature. Elle offre un temps d'exécution des plus faibles avec une très grande robustesse au bruit. Son utilisation est

très intéressante pour une segmentation rapide sur images couleurs ou des images médicales plus complexes.

AFCF utilise la super-résolution et l'algorithme de *Density Peak* pour trouver automatiquement le nombre de clusters, et l'analyse de covariance et des champs aléatoires de Markov pour améliorer la segmentation. Cependant, son temps de calcul est élevé et la segmentation et sa robustesse peuvent encore être améliorées. Cet algorithme est à utiliser dans le cas où la décision d'un nombre de *clusters* est difficile.

WRFCM utilise les résidus de bruits entre l'image originale et l'image idéale. Sa limitation c'est qu'elle perd en temps de calcul. Cependant, WRFCM donne d'excellents résultats sur des images très complexes, sans pour autant perdre les détails de l'image originale. L'utilisation de cette approche est conseillée sur les images très complexes avec du bruit inconnu ou mélangé.

KLDFCM utilise plusieurs approches simultanément, telles que la divergence KL, la reconstruction morphologique et les ondelettes. Cette méthode arrive à améliorer le résultat de la segmentation, mais son temps de calcul est plus élevé, en plus d'introduire de nouveaux paramètres à ajuster. Au final, cette méthode est un cas d'études intéressant, en proposant de combiner autant d'approches, et faire une analyse sur l'importance de chaque approche dans l'algorithme. Cette approche pourrait laisser place à plus d'améliorations et pourrait être utilisée sur d'autres types d'images tels que les images satellitaires.

	Information Spatiale	Fonction <i>Kernel</i>	Méthode mathématique
Type d'image	Images médicales, ou synthétiques en niveau de gris	Images médicales, et images naturelles	Images couleurs, synthétiques complexes, images médicales
Type de bruit	Gaussien	Gaussien, sel et poivre, rien	Inconnu ou mélangé
Temps de calcul	Court	Long	Court

Tableau 4. récapitulatif des caractéristiques à prendre pour les catégories de *clustering Fuzzy C-Means*.

4 Conclusion

La segmentation d'image est un domaine très important dans la vision par ordinateur, et a une grande utilité dans différentes applications. C'est pour cela qu'on retrouve un grand nombre d'approches dans la littérature qui essaie de résoudre ce problème. L'une des approches les plus populaires est le *clustering* flou avec l'algorithme Fuzzy C-Means. Cependant, cette segmentation grâce au flou fait face à des problèmes récurrents qui peuvent être résumés en :

- Robustesse face aux bruits.
- Temps de calcul.
- Automatisation des paramètres ajustables.

Dans la littérature beaucoup d'approches ont été proposées pour résoudre ces problèmes, et nous avons présenté les méthodes les plus importantes. En comparant ces

approches, nous avons vu des algorithmes très efficaces, et d'autres qui le sont moins mais proposent des idées intéressantes qui sont améliorées par la suite.

Finalement, même si la recherche dans ce domaine reste ouverte, nous avons clairement pu voir l'avancée de ce domaine et l'amélioration des résultats à travers les méthodes.

Références

- [1] Senthilkumaran, N., Rajesh, R.: 'A study on edge detection methods for image segmentation'. Proc. Int. Conf.. Mathematics and Computer Science (ICMCS-2009), 2009, Vol. I, pp. 255–259
- [2] F. Masulli and S. Rovetta, "Soft transition from probabilistic to possibilistic fuzzy clustering," IEEE Trans. Fuzzy Syst., vol. 14, no. 4, pp. 516–527, Aug. 2006.
- [3] H. Cao, H. W. Deng and Y. P. Wang, "Segmentation of M-FISH images for improved classification of chromosomes with an adaptive fuzzy c-means clustering algorithm," IEEE Trans. Fuzzy Syst., vol. 20, no. 1, pp. 1–8, Feb. 2012.
- [4] Zhu, S.C., Yuille, A.: 'Region competition: unifying snakes, region growing, and Bayes/MDL for multiband image segmentation', IEEE Trans. Pattern Anal. Mach. Intell., 1996, 18, (9), pp. 884–900.
- [5] V. Grau, A. U. J. Mewes, M. Alcaniz, R. Kikinis and S. K. Warfield, "Improved watershed transform for medical image segmentation using prior information," IEEE Trans. Med. Imag., vol. 23, no. 4, pp. 447–458, Apr. 2004
- [6] Caselles, V., Kimmel, R., Sapiro, G.: 'Geodesic active contours', Int. J. Comput. Vis, 2007, 21, (1), pp. 61–79.
- [7] Zheng, C., Qin, Q., Liu, G., Hu, Y.: 'Image segmentation based on multiresolution Markov random field with fuzzy constraint in wavelet domain', IET Image Process., 2012, 6, (3), pp. 213–221.
- [8] Dinggang, S., Horace, H.S.: 'A Hopfield neural network for adaptive image segmentation: an active surface paradigm', Pattern Recognit. Lett., 1997, 18, (1), pp. 37–48.
- [9] L. Zadeh, "Fuzzy sets," Inf. Control, vol. 8, pp. 338–353, 1965.
- [10] Bezdek, James & Ehrlich, Robert & Full, William. "FCM—the Fuzzy C-Means clustering-algorithm". Computers & Geosciences.
- [11] M. Ahmed, S. Yamany, N. Mohamed, A. Farag, and T. Moriarty, "A modified fuzzy C-means algorithm for bias field estimation and segmentation of MRI data," IEEE Trans. Med. Imag., vol. 21, no. 3, pp. 193–199, Aug. 2002.
- [12] L. Szilagyi, Z. Benyo, S. Szilagyi, and H. Adam, "MR brain image segmentation using an enhanced fuzzy C-means algorithm," in Proc. 25th Annu. Int. Conf. IEEE EMBS, Sep. 2003, pp. 724–726.
- [13] S. Chen and D. Zhang, "Robust image segmentation using FCM with spatial constraints based on new kernel-induced distance measure," IEEE Trans. Syst. Man Cybern. Part B Cybern., vol. 34, no. 4, pp. 1907–1916, Aug. 2004.
- [14] W. Cai, S. Chen, and D. Zhang, "Fast and robust fuzzy c-means clustering algorithms incorporating local information for image segmentation," Pattern Recognit., vol. 40, no. 3, pp. 825–838, Mar. 2007.
- [15] S. Krinidis and V. Chatzis, "A robust fuzzy local information C-means clustering algorithm," IEEE Trans. Image Process., vol. 19, no. 5, pp. 1328–1337, Jan. 2010.

- [16] M. Gong, Y. Liang, J. Shi, W. Ma, and J. Ma, "Fuzzy C-means clustering with local information and kernel metric for image segmentation," *IEEE Trans. Image Process.*, vol. 22, no. 2, pp. 573–584, Feb. 2013.
- [17] M. Gong, Z. Zhou, and J. Ma, "Change detection in synthetic aperture radar images based on image fusion and fuzzy clustering," *IEEE Trans. Image Process.*, vol. 21, no. 4, pp. 2141–2151, Apr. 2012.
- [18] L. Szilágyi, "Lessons to learn from a mistaken optimization," *Pattern Recognition Letters*, vol. 36, no. 1, pp. 29–35, 2014.
- [19] A. Elazab, C. Wang, F. Jia, J. Wu, G. Li, and Q. Hu, "Segmentation of brain tissues from magnetic resonance images using adaptively regularized kernel-based fuzzy-means clustering," *Comput. Math. Method. M.*, vol. 2015, pp. 1–12, Nov. 2015.
- [20] C. Wang, W. Pedrycz, J. Yang, M. Zhou and Z. Li, "Wavelet Frame-Based Fuzzy C-Means Clustering for Segmenting Images on Graphs," in *IEEE Transactions on Cybernetics*, vol. 50, no. 9, pp. 3938-3949, Sept. 2020
- [21] J.Gu, L.Jiao, S.Yang, and F.Liu, "Fuzzy double C-means clustering based on sparse self-representation," *IEEE Trans. Fuzzy Syst.*, vol. 26, no. 2, pp. 612–626, Apr. 2018.
- [22] T. Lei, X. Jia, Y. Zhang, L. He, H. Meng, and K. N. Asoke, "Significantly fast and robust fuzzy c-means clustering algorithm based on morphological reconstruction and membership filtering," *IEEE Trans. Fuzzy Syst.*, vol. 26, no. 5, pp. 3027–3041, Oct. 2018.
- [23] T. Lei, P. Liu, X. Jia, X. Zhang, H. Meng and A. K. Nandi, "Automatic Fuzzy Clustering Framework for Image Segmentation," in *IEEE Transactions on Fuzzy Systems*, vol. 28, no. 9, pp. 2078-2092, Sept. 2020.
- [24] C. Wang, W. Pedrycz, Z. Li and M. Zhou, "Residual-driven Fuzzy C-Means Clustering for Image Segmentation," in *IEEE/CAA Journal of Automatica Sinica*, vol. 8, no. 4, pp. 876-889, April 2021.
- [25] C. Wang, W. Pedrycz, Z. Li and M. Zhou, "Kullback–Leibler Divergence-Based Fuzzy C-Means Clustering Incorporating Morphological Reconstruction and Wavelet Frames for Image Segmentation," in *IEEE Transactions on Cybernetics*, vol. 52, no. 8, pp. 7612-7623, Aug. 2022.
- [26] P. Arbelaez, M. Maire, C. Fowlkes, and J. Malik, "Contour detection and hierarchical image segmentation," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 33, no. 5, pp. 898–916, May 2011.
- [27] R. Unnikrishnan, C. Pantofaru, and M. Hebert, "Toward objective evaluation of image segmentation algorithms," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 29, no. 6, pp. 929–944, Jun. 2007.
- [28] X. Wang, Y. Tang, S. Masnou, and L. Chen, "A global/local affinity graph for image segmentation," *IEEE Trans. Image Process.*, vol. 24, no. 4, pp. 1399–1411, Apr. 2015.
- [29] D. N. H. Thanh, D. Sergey, V. B. S. Prasath, and N. H. Hai. "Blood vessels segmentation method for retinal fundus images based on adaptive principal curvature and image derivative operators," *Int. Arch. Photogramm. Remote Sens. Spatial Inf. Sci.*, vol. XLII-2/W12, pp. 211–218, May 2019.
- [30] D. N. H. Thanh, U. Erkan, V. B. S. Prasath, V. Kumar, and N.N. Hien, "A skin lesion segmentation method for dermoscopic images based on adaptive thresholding with normalization of color models," in *Proc. IEEE 6th Int. Conf. Electr. Electron. Eng.*, Apr. 2019, pp. 116–120.
- [31] A. A. Taha and A. Hanbury, "Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool," *BMC Med. Imaging*, vol. 15, no. 29, pp. 1–29, Aug. 2015.